


让 Agent 的每次变化 都有可发布的证据

真实推理 · 受控副作用 · 行为级回归

Codex 改变 Agent，AgentRig 把改变固化成
Case、Run、Timeline、Sample 与 Gate。

EVIDENCE BEFORE CONFIDENCE



EDITFLOW · 30 / 30 PASS

公开脱敏 Agent · 真实 Agno + DeepSeek · 本地可复现

Prompt 改一行，Agent 行为可能变五层

最终回答相似，不代表工具选择、参数、顺序和结果引用仍然正确。

一次成功 Demo，
不足以批准一次发布。

Agent 的概率性与工具副作用，使传统单元测试和纯 Mock 都无法独立回答发布问题。

目标：真实决策，受控执行，可审计结论

01	工具选择	调用哪个工具，是否过度路由
02	参数传播	人物保护、素材 ID、图片引用
03	调用顺序	检查、修改、搜索、应用、裁剪
04	执行成本	图片、支付、发信与生产写入


AgentRig 不替 Agent 回答，只治理评测边界

模型仍真实推理：工具结果来源、事实记录与裁决责任被独立控制。



Identity → Asset → Run → Evidence → Gate

每一层都有稳定身份；历史 Run 不被修复动作覆盖。



同一事实链支持本地调试、团队评审、CI Gate 与生产回灌

不是一张绿色分数卡，而是一条可定位、可复跑、可追责的发布证据链。

不同能力可以给出不同方案，共享同一种证据合同

Codex 面向开发者闭环；Web 助手面向产品、运营与测试人员。

DEVELOPER

Codex + 项目 Skill + MCP

```
codex — editflow-demo-agent — run_cases · verdict

mcp: agentrig/preview_run_cases  completed  1 Cell · 5 Attempts · 0 skipped
mcp: agentrig/run_cases          completed  submitted

codex  Run run_79367abb0d5b4db2b743e143d130cb99 正在执行: 1/5 Attempt 已完成且为
pass, 另 1 个运行中、3 个排队; 不提前把父 Run 的运行状态当作行为结论。

mcp: agentrig/get_run            completed  status=completed

codex  逐条明细已确认: 5 个 Attempt 的 evaluation_state 均为 pass, 每次 5 次工具
调用、8/8 规则断言通过; 五次 capability snapshot 完全一致。

· Run ID    run_79367abb0d5b4db2b743e143d130cb99
· Manifest  sha256:bb5008e637bc33dafb...021586766aa (与 Before/Candidate 同一冻结身份)
· Attempt   1-5 · evaluation_state=pass · 8/8 assertions

$ uv run ruff check .          → All checks passed!
$ uv run pytest -m "not live" → 34 passed, 1 deselected

codex  结论: PARTIAL. 指定的一步式混合链在受控 fixture 环境下 5/5 pass;
但本会话未运行基线批次与完整 smoke 回归, 按 Skill 第 7 步不满足 ACCEPT 条件。
未修改任何文件, 未批准任何资产; 完整 ACCEPT 由全量回归台账支撑。
```

主入口 · 真实会话 · run_79367a...

PRODUCT / QA

AgentRig 智能评测助手

- 自然语言描述评测目标和成本边界
- 模型生成自己的可编辑计划
- 高成本执行必须人工确认
- 复用 Target、Case、Run 与报告资产

辅助入口 · 无需 MCP 知识

不要求两种模型生成同一方案；要求每个结论都能回到冻结资产和运行证据。

EditFlow：可复现、可脱敏、仍然足够真实

以 lassist 的真实修图链路为基础，去除私有素材、版本与基础设施依赖。

OPEN DEMO AGENT

Agno + DeepSeek

PostgreSQL Session
HTTP/SSE Target
External tool execution
Local deterministic MCP

不上传图片 · 不调用第三方图片 API

01	inspect_image	读取图片属性与主体
02	retouch_photo	亮度、对比度等像素调整
03	search_assets	搜索受控素材并返回真实 ID
04	apply_asset	消费素材 ID 与最新图片引用
05	crop_photo	按目标比例裁剪

真实：模型、协议、Session、工具决策 | 受控：图片工具结果

同一冻结 Case 跑 5 次：2 Pass / 3 Behavior Fail

单次成功掩盖模型方差：父 Run completed 不等于业务验收通过。

HEADLINE TASK

一步完成调亮、
雪山背景与 4:5 裁剪，
并保持人物。

case_editflow_one_step_mixed_chain

Manifest bb5008e6...6766aa

Prompt SHA 43157c...9572

2

Pass

3

Behavior Fail

5

Independent Attempts

失败轨迹

retouch_photo → inspect_image → search_assets →
apply_asset → crop_photo

检查有时落在调亮之后，违反“先检查再修改”的冻结行为契约。

Run run_61e76493...8d9c03

不是盲目增加用例，而是按 Prompt Diff 治理风险

项目 Skill 先冻结身份与不变量，再查询 AgentRig 资产并分类。

REUSE

复用

已有用例已覆盖，直接进入矩阵

CHANGE

增强

行为契约变化，增强现有断言

NEW

新增

变更引入新风险，现场创建

EXCLUDE

排除

与本次 Prompt Diff 无关

本次防回归矩阵

Change	brighten_only_no_over_routing	简单调亮不能拆成素材或裁剪
Change	asset_search_miss_no_invention	搜索为空不能编造 asset_id
Change	preserve_subject_propagation	人物保护必须跨工具传播
New	one_step_mixed_chain_boundary	一步完成也不能绕过专用工具边界

Draft → 人工审核 → approved; 创建者不能批准自己创建的资产。

只改模型可见边界，并用 Prompt SHA 证明 Candidate 已生效

HTTP/SSE 适配层没有加入关键词路由，也没有为视频写死答案。

```
codex — editflow-demo-agent — prompt-regression-governance

$ codex exec "使用 $prompt-regression-governance Skill 完成一次候选提示词的回归确认..."

codex 读取 .codex/skills/prompt-regression-governance/SKILL.md

Skill 边界已锁定：只接受 Agno 内部的模型路由改动；五个图像工具保持外部执行；
不得以 HTTP 层短语匹配或伪造回答绕过模型；保留工作区、逐步 output_image_ref、
搜索来源资产 ID、preserve_subject、调用上限与中文答复等不变量。
5 次重复必须是独立 Attempt；任何失败先归类为行为、Case、评估器或基础设施问题。

mcp: agentrig/get_target      completed
mcp: agentrig/get_test_case   completed  case_editflow_one_step_mixed_chain · approved

$ git diff recording-baseline-v1..HEAD -- src/editflow/prompts/system.md

- `retouch_photo` 接受自然语言修图指令，可处理曝光、色彩、清理，也可尽量一次完成组合编辑。
- 为提高响应速度，复杂编辑优先合并为最少工具调用；只有一个工具明显不能表达时才拆分。
+- `retouch_photo` 只调整当前图片自身的曝光、色彩、皮肤和画面清理；不能替换背景或改变画幅比例。
+- 背景或装饰素材必须先用 `search_assets` 查找，再把本轮返回的 `asset_id` 交给 `apply_asset`。
+- 复合任务按真实数据依赖拆分。改变图片后先读取 `output_image_ref`，再作为下一步 `image_ref`。

codex 它消除了两项歧义：「组合编辑可交给 retouch_photo」与「优先减少调用」。

Prompt 身份：
· Baseline commit f38257dd · Prompt SHA 43157c294fef...f879572
· Candidate commit 已冻结 · Prompt SHA 71adb390cb86...5dff7fd (运行时实证)
· 模型标识 deepseek-v4-flash · worktree clean
```

BEFORE

43157c...9572

CANDIDATE

71adb3...f7fd


SHA 不变，Candidate 就没有验收资格

真实 Codex 会话：读取 Skill → MCP 冻结身份 → 最小 Prompt Diff (修改范围：system.md + tool description)

仓库门禁：34 tests passed

同 Case 5/5；六 Case 矩阵 30/30

每次 Attempt 都独立执行；没有用一个绿色总分掩盖方差。



不只验证最终文字：完整 Timeline 可以下钻

工具参数、Provider 来源、结果引用与裁决都关联同一 Attempt。

AgentRig

被测 Agent 工作区
评测控制台

工作区

评测

资产

观测

评测管理

01 运行记录

02 测试用例

03 用例审核

04 版本对比

05 评测报告

返回被测 Agent

Cell 证据
Attempt、时间线与恢复

EditFlow public Agno image agent 本机 working-tree http_sse AgentRig

← 返回 Run

Cell · Attempt Evidence
case_editflow_mixed_chain
target_editflow_http_sse · working-tree · 5 个独立 Attempt

CELL 结论 通过	失败分类 无	完成 ATTEMPT 5 / 5	CELL ID sha256:c3_83130f
---------------	-----------	---------------------	-----------------------------

Capability Snapshot
运行环境快照

采集状态 完整	Runtime / 协议 agno / http_sse
工具权限模式 controlled	已声明能力 8
缺失字段 0	Snapshot Hash sha256:43_84dc80

Evidence Timeline
执行与评判证据

1 通过 eval_atte_745030

2 通过 eval_atte_481de1

3 通过 eval_atte_81dde3

4 通过 eval_atte_f03bbb

5 通过 eval_atte_cdfcf9

冻结能力快照
AgentRig · Attempt 1
查看原始证据


发送测试消息
用户 · Attempt 1
把照片调亮一点，换成雪山背景，再裁成 4:5，人物不要改变。
查看原始证据

- 1 inspect_image
- 2 search_assets
- 3 retouch_photo
- 4 apply_asset
- 5 crop_photo

- ✓ asset_id 来自搜索
- ✓ preserve_subject 传播
- ✓ image_ref 逐步更新


真实工具结果，如何变成可审核的零真实调用回归资产

真实来源、人工责任和重复成本被放进同一条证据链。



自然语言规划，确认与提交分离

无需理解 MCP；成本边界和人工责任仍由 Core 强制执行。



1

Case

3

Attempts

01 生成 Draft Plan

02 重复执行触发确认

03 confirm 不创建 Run

04 submit 才执行

run_a1c88b...23fb
3 / 3 PASS

不是 EditFlow 专用脚本，而是可替换的评测控制面

框架、结果来源、裁决方式和消费入口彼此解耦。

入口	Codex / MCP · Web Assistant · CLI · CI
Driver	HTTP/SSE · OpenAI-compatible · AgentScope · AG-UI
Provider	Fixture · Approved Sample · Simulator · Real Tool
Evidence	Manifest · Cell · Attempt · Event · Timeline
Decision	Rule · Judge · Human Review · Report · Release Gate

- Project isolation
- Audit log
- Durable job
- OTLP → Case
- Failure patterns

核心模块可单独使用；AgentTeams 只在动态策展或语义裁决需要时启用。

把 AgentScope 的真实闭环经验，抽成可本地部署的开放合同

AgentRig 不是复制一个内部页面，而是开放身份、资产、运行、证据和 Gate。

01

AgentScope 实践

- 真实业务评测闭环
- 工作台交互经验
- AgentTeams 协作范式

02

AgentRig 开源内核

- 协议无关 Driver
- 低副作用 Provider
- Canonical Evidence

03

生态消费方式

- Codex + 项目 Skill
- 普通用户 Web Assistant
- CI / 发布 Gate

公开 EditFlow 证明可复现 | 真实 lassist 兼容验证证明不是只适配 Demo Agent

正式录制已闭环；全部证据来自干净录制库

已证明的事实与尚未证明的边界必须同时出现在结论里。

Before2 / 53 次行为失败	Headline5 / 5同 Case + Manifest	Matrix30 / 306 Cells
Sample replay5 / 50 real_tool	Web Assistant3 / 3确认与提交分离	EditFlow34 testsnon-live

诚实边界

Sample 仅覆盖 inspect_image；动态引用等值以 Timeline 展示；正式录制必须生成新 ID；AgentTeams 外部 Live、目标容量与生产 SLO 不冒充本次 EditFlow 结论。

Codex 负责思考和改变软件；AgentRig 负责让每次改变可复用、可执行、可追溯。