


让 Agent 的每次变化 都有可发布的证据

真实推理 · 受控副作用 · 行为级回归

Codex 改变 Agent，AgentRig 把改变固化成
Case、Run、Timeline、Sample 与 Gate。

EVIDENCE BEFORE CONFIDENCE



EDITFLOW · 30 / 30 PASS

公开脱敏 Agent · 真实 Agno + DeepSeek · 本地可复现

Prompt 改一行，Agent 行为可能变五层

最终回答相似，不代表工具选择、参数、顺序和结果引用仍然正确。

一次成功 Demo，
不足以批准一次发布。

Agent 的概率性与工具副作用，使传统单元测试和纯 Mock 都无法独立回答发布问题。

目标：真实决策，受控执行，可审计结论

01	工具选择	调用哪个工具，是否过度路由
02	参数传播	人物保护、素材 ID、图片引用
03	调用顺序	检查、修改、搜索、应用、裁剪
04	执行成本	图片、支付、发信与生产写入


AgentRig 不替 Agent 回答，只治理评测边界

模型仍真实推理：工具结果来源、事实记录与裁决责任被独立控制。



Identity → Asset → Run → Evidence → Gate

每一层都有稳定身份；历史 Run 不被修复动作覆盖。



同一事实链支持本地调试、团队评审、CI Gate 与生产回灌

不是一张绿色分数卡，而是一条可定位、可复跑、可追责的发布证据链。

不同能力可以给出不同方案，共享同一种证据合同

Codex 面向开发者闭环；Web 助手面向产品、运营与测试人员。

DEVELOPER

Codex + 项目 Skill + MCP

```
>_ OpenAI Codex (v0.147.0)
model:      gpt-5.6-sol · reasoning max
directory:  ~/Desktop/Project/editflow-demo-agent
permissions: V0L0 mode · mcp: agentrig → http://127.0.0.1:8024/mcp/

mcp: agentrig/preview_run_cases (completed) 1 Cell · 5 独立 Attempt · 0 跳过

codex
预览通过:解析到且仅解析到目标 Case;预览 Manifest 为 sha256:bb5008e637bc..586766aa. 现在携带该哈提交完全相同的请求,防止资产漂移。

mcp: agentrig/run_cases (completed) submitted · run_33efe83470d54f728f1dc6b0dad36153
  • Working (41s · esc to interrupt)

mcp: agentrig/get_run_summary (completed) 3/5 completed · 3 pass

codex
运行进度为 3/5,当前三次均为 pass,尚无失败分类;剩余两次仍在排队/运行。我会继续轮询到终态,不用当前平均结果提前下结论。

mcp: agentrig/get_run_summary (completed) completed · pass: 5
mcp: agentrig/get_run_cell (completed) 5/5 Attempt · evaluation_state=pass
mcp: agentrig/list_case_run_events (completed) 逐 Attempt 核对工具顺序与参数

codex
唯一 Cell 及五个 Attempt 均为 completed/pass,每次恰好 5 次工具调用;五次能力快照一致:deepseek-v4-flash. Prompt SHA 71adb390..f7fd. 同一进程启动时间。父 Run 的 completed 本身不作为行为通过依据。

$ uv run ruff check . → All checks passed!
$ uv run pytest -m "not live" → 34 passed, 1 deselected

结论:PARTIAL
指定的 headline hard Case 已获 5/5 独立 Attempt 通过(Run run_33efe834_,Manifest sha256:bb5008e6..66aa,与 Before/Candidate 同一冻结身份);但本批次未覆盖 Skill 第 6 步要求的五类语义冒烟回归,不满足 ACCEPT 的完整门槛。未修改文件、未批准任何资产。

gpt-5.6-sol · ~/Desktop/Project/editflow-demo-agent · tokens used 112,373
```

主入口 · 真实会话 · run_33efe8...

PRODUCT / QA

AgentRig 智能评测助手

- 自然语言描述评测目标和成本边界
- 模型生成自己的可编辑计划
- 高成本执行必须人工确认
- 复用 Target、Case、Run 与报告资产

辅助入口 · 无需 MCP 知识

不要求两种模型生成同一方案；要求每个结论都能回到冻结资产和运行证据。

EditFlow：可复现、可脱敏、仍然足够真实

以 lassist 的真实修图链路为基础，去除私有素材、版本与基础设施依赖。

OPEN DEMO AGENT

Agno + DeepSeek

PostgreSQL Session
HTTP/SSE Target
External tool execution
Local deterministic MCP

不上传图片 · 不调用第三方图片 API

01	inspect_image	读取图片属性与主体
02	retouch_photo	亮度、对比度等像素调整
03	search_assets	搜索受控素材并返回真实 ID
04	apply_asset	消费素材 ID 与最新图片引用
05	crop_photo	按目标比例裁剪

真实：模型、协议、Session、工具决策 | 受控：图片工具结果

同一冻结 Case 跑 5 次：2 Pass / 3 Behavior Fail

单次成功掩盖模型方差：父 Run completed 不等于业务验收通过。

HEADLINE TASK

一步完成调亮、
雪山背景与 4:5 裁剪，
并保持人物。

case_editflow_one_step_mixed_chain

Manifest bb5008e6...6766aa

Prompt SHA 43157c...9572

2

Pass

3

Behavior Fail

5

Independent Attempts

失败轨迹

retouch_photo → inspect_image → search_assets →
apply_asset → crop_photo

检查有时落在调亮之后，违反“先检查再修改”的冻结行为契约。

Run run_61e76493...8d9c03

不是盲目增加用例，而是按 Prompt Diff 治理风险并沉淀存档

项目 Skill 先冻结身份与不变量、分类资产，最终把整次迭代固化为 PI 存档。

REUSE

复用

已有用例已覆盖，直接进入矩阵

CHANGE

增强

行为契约变化，增强现有断言

NEW

新增

变更引入新风险，现场创建

EXCLUDE

排除

与本次 Prompt Diff 无关

docs/prompt-iterations/
└─ PI-20260814-01-one-step-mixed-chain-routing/
 └─ README.md # 人话报告：范围·证据·判定
 └─ artifacts/
 └─ prompt.before.md # 变更前完整 Prompt
 └─ prompt.after.md # 变更后完整 Prompt
 └─ before-identity.json
 └─ after-identity.json
 └─ cases.json # reuse/change/new/excl
 └─ runs.json # 全部 Run/Manifest/逐 #
 └─ change.json # 最小修改与动机
 └─ metrics.json # before/after 通过率

PI-20260814-01 · 一步式混合链路由收紧

结论:ACCEPT · Before 2/5(3× behavior_regression)→ Candidate 5/5 · 矩阵 30/30

范围与不变量

项目	内容
模型输入变更	system.md Routing 五条规则重写:inspect 前置、retouch 限定像素调整、素材必须搜索后应用、画幅唯一入口、按数据依赖拆分并逐步消费 output_image_refcatalog.py 中 retouch_photo 描述同步收紧
必须保持	选中工作区;素材 ID 来自本轮搜索:preserve_subject 传播;调用有界;中文回复;HTTP 适配层零路由逻辑

身份

	commit	Prompt SHA
Before	f38257dd(tag recording-baseline-v1)	43157c29_79572
After	12475f39	71adb390_diff77fd(运行时实测)

证据(干净录制库)

批次	Run	结果
Before headline	run_61e76493...	2/5.3× behavior_regression
Candidate headline	run_b8ac3aa9...	5/5.同 Manifest
回归矩阵	run_3afacf3d...	30/30.6 Cells
Codex CLI 确认	run_79367abb...	5/5:范围外如实 PARTIAL
Sample 采样→同放	run_db173d3e... → run_1a289c84...	5/5:real_tool Attempt=0

本次防回归矩阵

Change

brighten_only 不过度路由

Change

asset miss 不编造 asset_id

Change

preserve_subject 跨工具传播

New

一步完成不破坏专用工具边界

Draft → 人工审核 → approved;
创建者不能批准自己创建的资产

迭代存档 docs/prompt-iterations/PI-20260814-01: before/after Prompt · 身份 · 用例 · Run · 指标 · 报告

AgentRig · GOAI 2026 · REVIEW

08 / 16

只改模型可见边界，并用 Prompt SHA 证明 Candidate 已生效

HTTP/SSE 适配层没有加入关键词路由，也没有为视频写死答案。

```
>_ OpenAI Codex (v0.147.0)
model:      gpt-5.6-sol · reasoning max
directory:  ~/Desktop/Project/editflow-demo-agent
permissions: YOLO mode · mcp: agentrig → http://127.0.0.1:8024/mcp/

  › 使用 $prompt-regression-governance Skill 完成一次候选提示词的回归确认___

$ sed -n '1,240p' .codex/skills/prompt-regression-governance/SKILL.md

codex
本次边界是：只把模型可见 Prompt 的候选差异转化为可复现证据，不触碰 HTTP 层路由、不调用真实图片 API、不改变或批准任何 AgentRig 资产；必须保持工作区选择、逐步 output_image_ref 传播、素材 ID 来源、
preserve_subject、有界调用和中文回复等不变量，五次重复必须是独立 Attempt。接下来先读取 Target 与 Case 的冻结身份。

mcp: agentrig/get_target (completed)
mcp: agentrig/get_test_case (completed) case_editflow_one_step_mixed_chain · approved

codex
冻结身份已确认：Target 为 target_editflow_http_sse(http_sse,Agno 2.6.11);Case 为已批准的 case_editflow_one_step_mixed_chain,主评估器是确定性 rule。它明确要求 inspect → retouch、
search → apply、retouch → apply → crop 三组顺序，以及两次结果引用接力和 preserve_subject=true。现在读取基线到工作树的唯一 Prompt 差异。

$ git diff recording-baseline-v1..HEAD -- src/editflow/prompts/system.md
- `retouch_photo` 接受自然语言修图指令，可处理曝光、色彩、清理，也可尽量一次完成组合编辑。
- 为提高响应速度，复杂编辑优先合并为最少工具调用；只有一个工具明显不能表达时才拆分。
+ `retouch_photo` 只调整当前图片自身的曝光、色彩、皮肤和画面清理；不能替换背景或改变画幅比例。
+ 背景或装饰素材必须先调用 `search_assets` 查找，再把本轮返回的 `asset_id` 交给 `apply_asset`。
+ 复合任务按真实数据依赖拆分。改变图片后先读取 `output_image_ref`，再作为下一步 `image_ref`。
Baseline commit f38257dd(tag recording-baseline-v1) · Prompt SHA 43157c294fef..f879572
Candidate Prompt SHA 71adb390cb86...5dff7fd(运行时 /capabilities 实证) · deepseek-v4-flash

gpt-5.6-sol · ~/Desktop/Project/editflow-demo-agent · tokens used 112,373
```

BEFORE

43157c...9572

CANDIDATE

71adb3...f7fd


SHA 不变，Candidate 就没有验收资格

真实 Codex 会话：读取 Skill → MCP 冻结身份 → 最小 Prompt Diff (修改范围：system.md + tool description)

仓库门禁：34 tests passed

同 Case 5/5；六 Case 矩阵 30/30

每次 Attempt 都独立执行；没有用一个绿色总分掩盖方差。



6

Cells

30

Attempts

30

Pass

0

Fail

headline
2 / 5 → 5 / 5

run_3afacf...4793

不只验证最终文字：完整 Timeline 可以下钻

工具参数、Provider 来源、结果引用与裁决都关联同一 Attempt。

AgentRig

被测 Agent 工作区
评测控制台

工作区

评测

资产

观测

评测管理

01 运行记录

02 测试用例

03 用例审核

04 版本对比

05 评测报告

返回被测 Agent

Cell 证据
Attempt、时间线与恢复

EditFlow public Agno image agent 本机 working-tree http_sse AgentRig

← 返回 Run

Cell - Attempt Evidence
case_editflow_mixed_chain
target_editflow_http_sse - working-tree - 5 个独立 Attempt

CELL 结论 通过	失败分类 无	完成 ATTEMPT 5 / 5	CELL ID sha256:c3_83130f
---------------	-----------	---------------------	-----------------------------

Capability Snapshot
运行环境快照

采集状态 完整	Runtime / 协议 agno / http_sse
工具权限模式 controlled	已声明能力 8
缺失字段 0	Snapshot Hash sha256:43_84dc80

Evidence Timeline
执行与评判证据

1 通过 eval_atte_745030

2 通过 eval_atte_481de1

3 通过 eval_atte_81dde3

4 通过 eval_atte_f03bbb

5 通过 eval_atte_cdfcf9

冻结能力快照
AgentRig - Attempt 1
查看原始证据

2026-08-14 22:48:50

发送测试消息
用户 - Attempt 1
把照片调亮一点，换成雪山背景，再裁成 4:5，人物不要改变。
查看原始证据


2026-08-14 22:48:50

- 1 inspect_image
- 2 search_assets
- 3 retouch_photo
- 4 apply_asset
- 5 crop_photo

- ✓ asset_id 来自搜索
- ✓ preserve_subject 传播
- ✓ image_ref 逐步更新


真实工具结果，如何变成可审核的零真实调用回归资产

真实来源、人工责任和重复成本被放进同一条证据链。



自然语言规划，确认与提交分离

无需理解 MCP；成本边界和人工责任仍由 Core 强制执行。



1

Case

3

Attempts

01 生成 Draft Plan

02 重复执行触发确认

03 confirm 不创建 Run

04 submit 才执行

run_a1c88b...23fb
3 / 3 PASS

不是 EditFlow 专用脚本，而是可替换的评测控制面

框架、结果来源、裁决方式和消费入口彼此解耦。

入口	Codex / MCP · Web Assistant · CLI · CI
Driver	HTTP/SSE · OpenAI-compatible · AgentScope · AG-UI
Provider	Fixture · Approved Sample · Simulator · Real Tool
Evidence	Manifest · Cell · Attempt · Event · Timeline
Decision	Rule · Judge · Human Review · Report · Release Gate

- Project isolation
- Audit log
- Durable job
- OTLP → Case
- Failure patterns

核心模块可单独使用；AgentTeams 只在动态策展或语义裁决需要时启用。

把 AgentScope 的真实闭环经验，抽成可本地部署的开放合同

AgentRig 不是复制一个内部页面，而是开放身份、资产、运行、证据和 Gate。



真实工程 Skill 生态 (lassist · 已脱敏)

公开 EditFlow 证明可复现 | 真实 lassist 兼容验证证明不是只适配 Demo Agent

01

AgentScope 实践

真实业务评测闭环 · 11 个评测/治理 Skill 常态使用 · AgentTeams 协作范式

02

AgentRig 开源内核

协议无关 Driver · 低副作用 Provider · Canonical Evidence

03

生态消费方式

Codex + 项目 Skill + PI 存档 · 普通用户 Web Assistant · CI / 发布 Gate

正式录制已闭环；全部证据来自干净录制库

已证明的事实与尚未证明的边界必须同时出现在结论里。

Before2 / 53 次行为失败	Headline5 / 5同 Case + Manifest	Matrix30 / 306 Cells
Sample replay5 / 50 real_tool	Web Assistant3 / 3确认与提交分离	EditFlow34 testsnon-live

诚实边界

Sample 仅覆盖 inspect_image；动态引用等值以 Timeline 展示；正式录制必须生成新 ID；AgentTeams 外部 Live、目标容量与生产 SLO 不冒充本次 EditFlow 结论。

Codex 负责思考和改变软件；AgentRig 负责让每次改变可复用、可执行、可追溯。