


让企业 Agent 的 每次变化都有证据

多 Agent 可审计评测基础设施

AgentTeams 负责协作。
AgentRig 负责事实、验证与审计。

EVIDENCE BEFORE CONFIDENCE



真实 lassist/Pixcake Agent · 三角色协作 · 成功与策略回归证据

2026.08 / v0.2.0a0

Agent 的风险，不止是回答错一次

真正困难的是：事后能否复原它为什么这样做。

输出可以看见，
过程往往不可见。

没有冻结上下文、执行事件和独立裁决，
一次“通过”既无法解释，也无法复现。

目标：把聊天质量问题，变成可持续验证的工程问题。

- 01

输出

随机结果让字符串快照失去解释力
- 02

工具

真实调用有成本和副作用；纯 mock 又不可信
- 03

裁决


Judge 可能看见答案、接受伪证据或自说自话
- 04

状态

版本、审批、多轮上下文与恢复共同决定行为

从一句目标，到一条可审计 Run

把平台对象藏在自然语言之后，把关键边界留给用户确认。



没有确认，不产生 Run

计划是领域对象，不是提示词里的建议。

三种职责，三条不可越过的边界

分工不是为了凑 Agent 数量，而是隔离知识、权限和裁决。

01 / Manager

把目标变成
可确认的计划

目标理解 · 资产选择 · 计划 · 诊断

边界

不能直接调用原始 run_cases

02 / Simulation Curator

生成合理、Schema 合法的工具结果

边界 · 看不到 rubric 与预期答案

03 / Evidence Judge

基于冻结证据独立裁决

边界 · 不能改执行，也不能造证据

隔离的结果：不越权、不泄漏目标、不让执行者自评。


AgentTeams 不是 PPT 依赖，而是运行时事实

身份、生命周期、工作区、MCP 路由与双向事件都可以现场核验。

协作框架拥有协作；
AgentRig 只接收可审计事件。

身份与生命周期	AgentTeams v1.1.2
任务与回执	Matrix request / response event ID
角色工作区	MinIO versioned roles + Skills
最小权限工具	Higress isolated MCP routes

Core 不依赖 AgentTeams 类型



1 三个真实角色 2 Worker 调用、输入/结果 hash 与事件回执

两条责任链，一份权威事实

AgentTeams 管“谁在协作”；AgentRig Core 管“究竟发生了什么”。

协作层




事实层



任何 Agent 都不能用聊天文本改写 RunEvent。

可复用能力，不是一次性 Prompt

11 个版本化 Skill；三套最小权限 MCP 工具集。




结论必须回到证据，而不是相信 Judge

确定性约束与语义判断独立保存，任何未知 evidence_ref 都会被拒绝。

01 冻结事实

- Case / Target / Profile 快照
- RunEvent / tool call / result
- Curator 看不到 rubric

02 独立评测



03 证据报告


The evidence report is displayed on a dark background. It features the text 'PASS 3 / 3' in large, bold, white letters. Below this, there are two lines of smaller white text: 'Rule 与 Judge 的结果互不覆盖' and '每个 verdict 都能追到 event / hash / evaluator'. A blue arrow points from the 'Evidence Judge' box in the previous section to this report, indicating that the report is the output of the evaluation process.

输出进入事实库之前：Pydantic / JSON Schema / hash / evidence reference 全部校验。

模型可以提议，只有确定性后端可以放行

审批、密钥、重试与失败终态都在 Prompt 之外执行。

计划状态机



01	02	03	04
Secret	Redaction	Idempotency	Terminal state
只存 env:/Secret 引用；不进 Matrix、日志和 Skill	模型与 Worker 输入统一脱敏	重复提交复用幂等键，不重复执行	超时、取消、失败均为显式可审计终态

AgentTeams 故障不会破坏 Core 与既有证据。

真实产品， 不是概念图

本机 lassist/Pixcake Agent

- 1三角色状态与当前计划
- 2成功 / 失败诊断
- 3Run 与 Matrix 双向 event ID

成功闭环 + 策略回归
均保留可引用证据

AgentRig

被测 Agent 工作区

评测控制位

工作区

评测

资产

观测

工作区导航

01 评测总览

02 对话验证

03 智能评测助手

返回被测 Agent

智能评测助手

AgentTeams 协作评测

智能评测会话

评测会话

输入新会话标题

新建

参赛验收 · 成功回归

28 个事件 · asst_391c1_a310f

2.1 自适应决策验收

25 个事件 · asst_96042_14ab4

新的评测会话

24 个事件 · asst_9254a_36991

参赛验收 · 确认策略

16 个事件 · asst_3d162_8d229

参赛验收 · 确认策略

13 个事件 · asst_e990b_68d77

lassist V2 最终并发安全验收

15 个事件 · asst_3cb85_8359b

lassist V2 最终回环验收

14 个事件 · asst_426ac_1ae3d

lassist V2 可演示验收

14 个事件 · asst_7b8c4_157ec

lassist V2 最终验收

38 个事件 · asst_64869_24929

lassist V2 全链路验收 (二次)

AgentTeams 已启用

Matrix 与协作角色运行正常

AgentTeams · 智能评测控制室

参赛验收 · 成功回归

自然语言规划 · 人工确认 · 可审计执行

3

Matrix 房间已就绪

!hwaV9XncF_18080

simulation_curator 已提交可验证证据 agentinv_b_b3515

评测运行已完成, Manager 正在基于证据诊断 run_7e70cc_5c945

evidence_judge 已提交可验证证据 agentinv_b_d6412

@manager:matrix-local:hlctawic:18080

Run 诊断: 通过

Run run_7e70ccf2cdb3468fb9286ce23ba5c945 — status completed, 无失败/跳过/取消, 无运行错误。

CaseRun: case_run_f5b0dcf617...d30ee36b3c4c53 (case_lassist_three_agent_demo, v9.2.0) → pass

1 轮对话, 1 次工具调用: 单一 candidate target, 无 A/B 对比。

独立评估 (均 pass, 未互相覆盖)

Rule (evaluation_401ef33279d14edc88d4fc56787dd395): 3/3 断言通过 —— 全局 no_execution_error、turn1 调用 apply_image_prompt、turn1 no_execution_error。

Evidence Judge (primary) (evaluation_f99be45e528f4613bbbd8be63bf59d3f): 三标准全 pass —— 正确理解背景增强意图并调用合适工具 (image_ids=[1])、工具成功 (success=true/record_id=1) 后给出简洁明确不夸大的反馈、无执行错误。均引用运行事件 (evt_02513f2e...等)。

结论: 基础设施/工具链路与产品行为均正常, 证据可追溯到具体事件: completed 与 pass 一致。属成功回归, 无需恢复动作。

诊断决策: decision_9948261c296740eead095a8004d14179 (no_action, succeeded)。无需后续处理; 如需要我可把该回归固化为回归用例。

04:05:52 #28

描述评测目标、范围或你想追查的问题...

Enter 发送 · Shift + Enter 换行

发送

自适应决策

当前决策

已完成

decision_9_34179

保留现状并解释

诊断已完成的 Run run_7e70ccf2cdb3468fb9286ce23ba5c945 并给出证据化结论。

策略版本 Core 已允许

证据引用 1

置信度 99%

决策成功率 100%

事实引用 6

结果可追溯 100%

动态协作拓扑

实际执行路径

Manager Core Gate lassist

评测主控 Manager AgentTeams 就绪

结果模拟 Curator AgentTeams 已完成

证据裁决 Judge AgentTeams 已完成

评测计划

当前计划

评测目标 · 修订版本 1

已准备评测目标

用例 1

用例运行 1

通过 0

结果提供者 simulation_curator

评判器 evidence_judge

查看 Run

可运行、可替换、可复核

Core 在无模型、无 AgentTeams 时仍能完成确定性回归。

134

backend tests passed

30 unit · 2 E2E · 0 secret hits

Python 3.12 · FastAPI · SQLAlchemy

React · MCP · MIT

本机一键运行与确定性验证

Core

没有模型与 AgentTeams 也能执行回归

Drivers

Pixcake / OpenAI-compatible / ACP / subprocess

Storage

SQLite 本机体验；Repository 契约可接 PostgreSQL

Extension

Driver / Provider / Evaluator / Skill / Adapter

Delivery

MIT · 部署文档 · Skills · 安全文档 · 自动测试

从“看起来能跑”，到“证据足够发布”

AgentRig 不替 Agent 做决定；它让每个决定都能回归、门禁与审计。

Evidence before confidence.

不同企业 Agent 共用的开源质量与发布基础设施



现在

三 Agent 协作
成功 / 回归证据
开源工程包



下一阶段

可执行 Trace 报告
恢复 / 性能指标
版本对比



规模化

PostgreSQL / K8s
OTel / SLS
发布门禁

让每次变化，都留下可核验的证据

三个 Agent 的身份合同

输入、输出、依赖、边界与追踪字段可与代码、MCP 路由和运行轨迹交叉核验。

字段	Evaluation Manager	Simulation Curator	Evidence Judge
角色	面向用户的评测编排	受控工具结果生成	基于证据的独立裁决
能力	资产选择 / 计划 / 审批 / 诊断	最小合理且 Schema 合法的候选	pass / fail / inconclusive + 引用
输入	会话 / 目标 / 权威资产事实	tool / args / schema / 脱敏历史	冻结 rubric / Rule / 脱敏证据
输出	Plan / Decision / Run 引用	CuratorGeneration / 结构化失败	JudgeOutput / criteria / refs
依赖	6 Manager Skills / MCP / Core	simulate-tool-result / Worker MCP	judge-evidence / Worker MCP
决策边界	不能原始 run_cases；提交绑定 event + revision	看不到 rubric；不调真实工具	不造证据；不足必须 inconclusive
审计追踪	AssistantEvent / Plan / Run / Matrix IDs	invocation / hash / event IDs	evaluation / hash / evidence refs

完整身份清单：docs/competition/02-Agent-Identity-清单.md

11 个 Skill 如何被工程化

不是名称清单：每个核心 Skill 都定义调用、失败、安全、验证与版本边界。

Skill inventory

Manager / 6	adaptive-evaluation
	plan-evaluation
	execute-evaluation-plan
	diagnose-run
	build-test-case-draft
Workers / 2	configure-test-target
	simulate-tool-result
	judge-evidence
Core / 3	run-test-cases
	build-test-case
	harvest-tool-samples

Official contract fields

01	名称 / 类型	02	使用场景
03	输入参数	04	输出结果
05	调用条件	06	依赖工具
07	失败处理	08	安全边界
09	验证 / 复用	10	版本 / 回滚

版本与回滚

随 AgentRig 0.2.0a0 进入 Git；锁定 AgentTeams v1.1.2；回滚完整 Release + 角色包，不热替换临场 Prompt。

完整逐 Skill 字段表：docs/competition/08-Skill-清单.md

上下文能力与当前验证台账

赛题要求四选二；AgentRig 已实现记忆、共享状态和轨迹可观测三项。

Context capabilities

Agent 记忆	已实现	Session / Turn / Event
知识库 RAG	未采用	当前评测场景不需要
共享状态	已实现	Plan / Invocation / Run
轨迹可观测	已实现	RunEvent / Eval / Matrix IDs / hash

Verification ledger

Backend	134 passed	6 skipped / 1 deprecation warning
Web	30 unit + 2 E2E	typecheck / coverage / build passed
Reference demo	3 scenarios	success / policy regression / recovery
Secret scan	0 findings	Gitleaks 8.29.1 + fixture sanity
Worker receipts	2 directions	Curator + Judge / Matrix event IDs

边界：未把云端 OTel/SLS、Kubernetes 与公开 Release/Tag 伪装为已完成。