



让企业 Agent 的每次变化 都有证据

多 Agent 可审计评测基础设施

AgentTeams 负责协作，AgentRig 负责事实、验证与审计。

AGENTTEAMS

MCP

EVALUATION

EVIDENCE

AUDIT

传统测试方法不适配 Agent

问题已经从“接口断言”升级为“执行治理”

01

输出不确定

字符串快照既脆弱，也无法解释语义是否正确。

02

工具有副作用

真实工具昂贵且修改数据；纯 mock 又缺少合理性。

03

Judge 不可信

可能看见预期答案、接受伪证据或脱离运行事实。

04

状态跨多轮

版本、工具链、审批和恢复共同决定最终行为。

目标不是再做一个聊天评分器，而是建立企业 Agent 的持续验证基础设施。

从一句目标到可审计 Run

把平台数据模型隐藏在自然语言交互之后



关键边界：计划不是提示词中的“建议”，而是可预览、可修订、可确认的领域对象。

三 Agent 职责分离，不为数量而拆分

不同知识、不同权限、不同可信边界

01

Manager

目标理解 · 资产选择
计划 · 审批 · 诊断

BOUNDARY

不能直接执行原始 run_cases

02

Simulation Curator

冻结上下文 · 工具候选
Schema 合规结果

BOUNDARY

看不到 rubric 与预期答案

03

Evidence Judge

冻结证据 · 独立裁决
引用真实 event ID

BOUNDARY

不能改执行，也不能造证据

合并角色会产生三类风险：越权执行 / 目标泄漏 / 执行者自评

AgentTeams 如何真实进入系统

不是 PPT 依赖：身份、生命周期、Skill 和双向事件均可现场核验

AgentTeams v1.1.2 Manager / Worker 生命周期与身份

Matrix 定向唤醒 · 任务投递 · 最终回执

MinIO 角色工作区 · 版本化 Skills

Higress 三身份隔离 MCP Routes



AGENTRIG ADAPTER

协作事件

映射


业务 Invocation

- | | |
|-----------------------|------------------------|
| • request_event_id | • run_id / case_run_id |
| • response_event_id | • role / deadline |
| • input / result hash | • result_ref |
| • terminal status | • error boundary |

Core 不依赖 AgentTeams 类型；协作框架可替换，业务事实合同不变。

协作层与事实层分离

AgentTeams 管“谁协作”，AgentRig Core 管“什么是事实”



IMMUTABLE EVIDENCE BOUNDARY

可复用能力，不是一次性 Prompt

11 个 Skill + 三套最小权限 MCP 工具集

MANAGER / 6

01 adaptive-evaluation

02 plan-evaluation

03 execute-evaluation-plan

04 diagnose-run

05 build-test-case-draft

06 configure-test-target

WORKERS / 2

01 simulate-tool-result

02 judge-evidence

CORE / 3

01 run-test-cases


02 build-test-case

03 harvest-tool-samples

每个核心 Skill：输入输出 · 调用条件 · 依赖 · 失败 · 安全 · 验证 · 复用 · 版本/回滚

防止“Judge 说通过就通过”

确定性约束与语义判断独立保存，结论必须回到证据



Rule / Judge / External 三类 Evaluation 互不覆盖；任何未知 evidence_ref 都会被拒绝。

审批、安全与恢复

模型只能提出动作，确定性后端决定动作是否允许发生



确认绑定 AssistantEvent + 同一 Plan Revision



SECRET

env: / Secret 引用；不进 Matrix、日志和 Skill

REDACTION

模型与 Worker 输入统一脱敏

IDEMPOTENCY

重复提交复用幂等键，不重复执行

TERMINAL

超时、取消、失败都是显式可审计终态

DEGRADE

AgentTeams 故障不破坏 Core 与既有证据

真实 Demo：成功、失败与证据

本机 lassist/Pixcake Agent · AgentTeams 三角色 · 双向 Matrix event ID

DEMO CONTRACT

01 成功闭环

apply_image_prompt → Curator → Rule 3/3 → Judge

02 策略回归

编辑前未二次确认 → Rule / Judge fail

03 审批边界

未确认不提交；revision 更新使旧确认失效

REAL TARGET / NO FAKE DRIVER

AgentRig

被测 Agent 工作区

评测控制台

工作区

评测

资产

观测

工作区导航

01 评测总览

02 对话验证

03 智能评测助手

返回被测 Agent

智能评测助手

AgentTeams 协作评测

智能评测会话

评测会话

输入新会话标题

新建

参赛验收 · 成功回归

28 个事件 · asst_391c1_a310f

V2.1 自适应决策验收

25 个事件 · asst_96042_1404

新的评测会话

24 个事件 · asst_9254a_36991

参赛验收 · 确认策略

16 个事件 · asst_3d162_0d229

参赛验收 · 确认策略

13 个事件 · asst_e990b_6b077

lassist V2 最终并安全验收

15 个事件 · asst_2c0b5_0390b

lassist V2 最终回执验收

14 个事件 · asst_420ac_1ae3d

lassist V2 可演示验收

14 个事件 · asst_7b0c4_157ec

lassist V2 最终验收

38 个事件 · asst_04869_24929

lassist V2 全链路验收 (二次)

AgentTeams 已启用

Matrix 与协作角色运行正常

AgentTeams · 智能评测控制台

参赛验收 · 成功回归

自然语言规划 · 人工确认 · 可审计执行

Matrix 房间已就绪

!hsaV9XncF_10080

simulation_curator 已提交可验证证据 agentinv_b_h3515

评测运行已完成, Manager 正在基于证据诊断 run_7e70cc-f2c0b3468fb9286ce23ba5c945

evidence_judge 已提交可验证证据 agentinv_b_d0412

@manager:matrix-local:hc1awic:18080

Run 诊断: 通过

Run [run_7e70cc-f2c0b3468fb9286ce23ba5c945] -- status completed, 无失败/跳过/取消, 无运行错误。

- CaseRun: [case_run_f5b0dc-f617a048caa4d30ee36b3c4c53] (case_lassist_three_agent_demo, v9.2.0) → pass
- 1 轮对话, 1 次工具调用: 单一 candidate target, 无 A/B 对比。

独立评估 (均 pass, 未互相覆盖)

- Rule (evaluation_401ef33279d14edc88d4fc56787dd395): 3/3 断言通过 —— 全局 no_execution_error, turn1 调用 apply_image_prompt, turn1 no_execution_error,
- Evidence Judge (primary) (evaluation_f99be45e528f4613bbbd8be63bf59d3f): 三标准全 pass —— 正确理解背景增强意图并调用合适工具 (image_ids=[1])、工具成功 (success=true/record_id=1) 后给出清晰明确不夸大的反馈、无执行错误。均引用运行事件 (evt_02513f2e...等)。

结论: 基础设施/工具链路与产品行为均正常, 证据可追溯到具体事件: completed 与 pass 一致, 属成功回归, 无需恢复动作。

诊断决策: decision_9948281c296740eead095a8004d14179 (no_action, succeeded)。无需后续处理: 如需要我可把该回归固化为回归用例。

04:05:52 #28

描述评测目标、范围或你想追查的问题。

Enter 发送 · Shift + Enter 换行

发送

自适应决策

当前决策

已完成

decision_9_34179

保留现状并解释

诊断已完成的 Run run_7e70cc-f2c0b3468fb9286ce23ba5c945 并给出证据化结论。

策略版本	证据引用	置信度
策略已允许	1	99%

决策成功率	事实引用	结果可追溯
100%	6	100%

动态协作提升

实际执行路径

Manager

Core Gate

lassist

评测主控 Manager

AgentTeams

就绪

结果模拟 Curator

AgentTeams

已完成

证据裁决 Judge

AgentTeams

已完成

评测计划

当前计划

已提交

评测目标 · 修订版本 1

已准备评测目标

用例	用例运行	跳过
1	1	0

结果提供链

simulation_curator

证据链

evidence_judge


查看 Run

AGENTRIG / GOAI 2026

10 / 12

工程落地与开放价值

Core 无模型、无 AgentTeams 仍可完成确定性回归



让每个 Agent 决定都经过分工、验证并留下证据

AgentRig 不替 Agent 做决定；它让决定可以持续回归、发布门禁与审计复盘

INITIAL

2026.08

公开设计与身份清单
真实三 Agent Demo
成功 / 失败证据

SEMIFINAL

NEXT

可执行代码包与视频
运行报告 / Trace
恢复与性能指标

FINAL

SCALE

PostgreSQL / Kubernetes
OTel / SLS 可观测
版本对比与发布门禁

不同企业 Agent 共用的开源质量与发布基础设施

AGENTRIG / EVIDENCE BEFORE CONFIDENCE

附录 A：三个 Agent 的完整身份合同

Name / Role / Capabilities / Inputs / Outputs / Dependencies / Decision Boundary / Trace

evaluation-manager Evaluation Manager CAPABILITIES 资产选择 · 计划/审批 · 诊断/用例草稿 INPUTS Session/Turn/Event · 用户目标 · 权威资产事实 OUTPUTS Plan/Decision/Run 引用 · 证据诊断 DEPENDENCIES 6 Manager Skills · manager MCP · Core DECISION BOUNDARY 不能原始 run_cases；确认/提交绑定用户 event + revision TRACE AssistantEvent · ManagerDecision · Plan/Run · Matrix IDs	simulation-curator Simulation Curator CAPABILITIES 生成最小合理、Schema 合法的受控结果 INPUTS invocation/hash/deadline · tool/args/schema · 脱敏历史 OUTPUTS CuratorGeneration 或分类结构化失败 DEPENDENCIES simulate-tool-result · Curator 三工具 MCP DECISION BOUNDARY 看不到 rubric/预期；不调真实工具；不枚举任务 TRACE Invocation 状态 · hashes · Matrix IDs · RunEvent ref	evidence-judge Evidence Judge CAPABILITIES 独立 pass/fail/inconclusive · 引用真实 event ID INPUTS invocation/hash/deadline · 冻结 rubric · Rule · 脱敏证据 OUTPUTS JudgeOutput · criteria · summary · evidence refs DEPENDENCIES judge-evidence · Judge 三工具 MCP DECISION BOUNDARY 不造证据/改 Rule；证据不足必须 inconclusive TRACE Invocation 状态 · hashes · Matrix IDs · Evaluation ID
---	---	---

附录 B：11 个 Skill 如何被工程化

不只列名称：定义调用、输入输出、失败、安全、验证、版本与复用

11 VERSIONED SKILLS	
MANAGER / 6	adaptive-evaluation plan-evaluation execute-evaluation-plan diagnose-run build-test-case-draft configure-test-target
WORKERS / 2	simulate-tool-result judge-evidence
CORE / 3	run-test-cases build-test-case harvest-tool-samples

OFFICIAL CONTRACT FIELDS	
01 名称 / 类型	02 使用场景
03 输入参数	04 输出结果
05 调用条件	06 依赖工具
07 失败处理	08 安全边界
09 验证 / 复用	10 版本 / 回滚

VERSION / RELEASE / ROLLBACK

当前随 AgentRig 0.2.0a0 进入 Git 版本管理；确定性构建三角色包，AgentTeams 基线锁定 v1.1.2；回滚完整 Release + 角色包，不单独热替换 Prompt。

完整逐 Skill 字段表：docs/competition/08-Skill-清单.md

上下文能力与当前可验证证据

赛题要求 4 选 2；AgentRig 实现记忆、共享状态和轨迹可观测 3 项

01 IMPLEMENTED Agent 记忆 Session / Turn / Event 恢复 Plan 与 Run 上下文	02 NOT NEEDED 知识库 RAG 当前场景不需要 未为数量堆叠检索链	03 IMPLEMENTED 共享状态 Plan / Invocation / Run 权威状态机	04 IMPLEMENTED 轨迹可观测 RunEvent / Evaluation / Decision Matrix IDs / hashes
134 后端测试通过 6 skipped / 1 deprecation warning	3 参考场景验证 success / policy regression / recovery	0 Git 历史密钥命中 Gitleaks 8.29.1 + official fixture sanity	
2 Worker 双向回执 Curator + Judge / Matrix event IDs	3/3 成功场景 Rule Evidence Judge 独立 pass	2/3 策略回归 Rule Judge 引用同一违规事件 fail	

边界：云端 OTel/SLS、Kubernetes、公开 Release/Tag 与最终视频仍按提交清单闭环，不伪装为已完成。